

LAPORAN UJIAN AKHIR SEMESTER
ANALISIS SENTIMEN KOMENTAR YOUTUBE PADA ISU DUGAAN
IJAZAH PALSU JOKO WIDODO: PERBANDINGAN SVM + TF-IDF DAN
INDOBERTWEET DI ATAS PIPELINE BIG DATA



Dosen Pengampu:

Dr. Eng. I Made Agus Dwi Suarjaya, S.T., M.Eng.

Mata Kuliah:

Big Data (A)

Disusun oleh:

Ida Bagus Gede Dhananjaya (2305551120)

Ravi Arnan Irianto (2305551076)

PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS UDAYANA
2026

DAFTAR ISI

BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan.....	2
1.4 Manfaat.....	2
1.5 Batasan Masalah.....	3
BAB II TINJAUAN PUSTAKA.....	4
2.1 Analisis Sentimen.....	4
2.2 Big Data dan Karakteristik 3V.....	4
2.3 MongoDB Atlas: Penyimpanan Terdistribusi.....	4
2.4 Apache Spark: Pemrosesan Terdistribusi.....	4
2.5 SVM dan Pembobotan TF-IDF.....	5
2.6 BERT dan IndoBERTweet.....	5
2.7 Pelabelan LLM-assisted dan Label Studio.....	5
2.8 Metrik Evaluasi.....	5
BAB III METODOLOGI.....	6
3.1 Arsitektur Pipeline.....	6
3.2 Pengumpulan Data.....	7
3.3 Pelabelan Data.....	8
3.4 Pra-pemrosesan Terdistribusi (Dua Jalur).....	9
3.5 Desain Dataset dan Pembagian Data.....	11
3.6 Pemodelan.....	11
3.7 Metrik Evaluasi.....	11
BAB IV HASIL DAN PEMBAHASAN.....	12
4.1 Hasil Pengumpulan dan Karakteristik Data.....	12
4.2 Analisis Data Eksploratif (EDA Terdistribusi).....	12

4.3 Hasil Pelabelan dan Validasi Manusia.....	12
4.4 Hasil Perbandingan Model (Dataset Final Seimbang 3.000).....	13
4.5 Analisis per Kelas dan Confusion Matrix.....	14
4.6 Eksperimen Kualitas Label.....	15
4.7 Jalur Big Data: SVM Spark vs scikit-learn.....	15
4.8 Kendala dan Solusi.....	16
BAB V PENUTUP.....	17
5.1 Kesimpulan.....	17
5.2 Saran.....	17
DAFTAR PUSTAKA.....	18
LAMPIRAN, PEMBAGIAN TUGAS (PIC).....	19

BAB I PENDAHULUAN

1.1 Latar Belakang

YouTube merupakan salah satu platform digital yang menyediakan ruang diskusi publik melalui kolom komentar. Pada isu-isu kontroversial, komentar YouTube menjadi rekaman langsung respons, dukungan, kritik, pertanyaan, dan perdebatan warganet. Data seperti ini bersifat tidak terstruktur, berbahasa non-baku, bercampur bahasa gaul dan emoji, serta memiliki volume besar, sehingga tidak efisien bila dianalisis secara manual dan menuntut pendekatan *Big Data*.

Salah satu isu yang ramai diperbincangkan adalah dugaan ijazah palsu Presiden ke-7 Republik Indonesia, Joko Widodo. Isu ini memicu ribuan komentar dengan sikap yang beragam: ada yang mempercayai dan menguatkan tuduhan, ada yang membantah dan mengkritik narasi tersebut, dan banyak pula yang sekadar bertanya atau menyampaikan informasi tanpa sikap yang jelas. Menganalisis sebaran sikap ini secara kuantitatif memerlukan pipeline lengkap: pengumpulan data, pelabelan, pemrosesan teks, hingga pemodelan klasifikasi.

Proyek ini membangun pipeline *end-to-end* analisis sentimen komentar YouTube berbahasa Indonesia seputar isu tersebut, dengan penekanan pada dua sisi. **Sisi Big Data:** seluruh data disimpan terpusat di basis data awan MongoDB Atlas dan sebagian besar pemrosesan dijalankan secara terdistribusi di atas *cluster* Apache Spark antar-mesin. **Sisi pemodelan:** membandingkan pendekatan *machine learning* klasik (SVM + TF-IDF) dengan pendekatan *deep learning* berbasis transformer (IndoBERTweet).

Hal yang membedakan proyek ini dari analisis sentimen umum adalah **penambatan (anchoring) polaritas ke narasi tuduhan, bukan ke sosok Jokowi**. Kelas *Positif* berarti mendukung/mempercayai tuduhan ijazah palsu, *Negatif* berarti menolak/membantah tuduhan, dan *Netral* berarti tidak jelas sikap atau sekadar bertanya/menyampaikan informasi. Definisi ini dituangkan dalam sebuah rubrik pelabelan yang dikalibrasi secara intensif agar konsisten.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam laporan ini adalah sebagai berikut:

1. Bagaimana merancang pipeline Big Data *end-to-end* untuk mengumpulkan, menyimpan, melabeli, dan memproses ribuan komentar YouTube berbahasa Indonesia secara terdistribusi?
2. Bagaimana strategi pra-pemrosesan teks yang tepat untuk dua paradigma model yang berbeda (bag-of-words vs. berbasis konteks)?
3. Antara SVM + TF-IDF dan IndoBERTweet, model manakah yang memberikan performa klasifikasi sentimen terbaik pada kondisi data seimbang?
4. Sejauh mana infrastruktur Big Data (MongoDB Atlas + Apache Spark) dapat menopang pipeline tersebut secara benar-benar terdistribusi?

1.3 Tujuan

Sejalan dengan rumusan masalah di atas, tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun pipeline analisis sentimen *end-to-end* di atas penyimpanan terdistribusi (MongoDB Atlas) dan pemrosesan terdistribusi (Apache Spark).
2. Menerapkan dua jalur pra-pemrosesan teks yang berbeda dan sesuai kebutuhan tiap paradigma model.
3. Melatih dan membandingkan dua model klasifikasi sentimen tiga kelas menggunakan metrik yang adil (macro-F1) pada *test set* identik.
4. Mendokumentasikan temuan, kendala teknis, dan solusinya sebagai pembelajaran penerapan Big Data pada kasus nyata.

1.4 Manfaat

Secara akademik, proyek ini menunjukkan penerapan konkret konsep Big Data (penyimpanan dan pemrosesan terdistribusi) pada kasus analisis teks berbahasa Indonesia, sekaligus membandingkan model klasik dan *deep learning* secara adil. Secara praktis, hasilnya memberi gambaran sebaran opini publik

terhadap suatu isu serta menjadi rujukan pemilihan model: kapan model klasik yang ringan sudah memadai, dan kapan transformer memberi keuntungan nyata.

1.5 Batasan Masalah

Agar pembahasan lebih terarah dan fokus, penelitian ini dibatasi pada hal-hal berikut:

1. Data hanya komentar berbahasa Indonesia dari 17 video YouTube terkait isu ijazah Jokowi; total 14.107 komentar mentah.
2. Klasifikasi dibatasi pada tiga kelas (Negatif, Netral, Positif) dengan polaritas ditambahkan ke narasi tuduhan.
3. Pelabelan berskala besar dilakukan secara *LLM-assisted*, dengan verifikasi manual pada sampel sebagai validasi.
4. Model dilatih dan dievaluasi hanya pada dataset seimbang 3.000 komentar (1.000 per kelas).
5. Fine-tuning transformer (IndoBERTweet) dijalankan di Google Colab (GPU) karena berada di luar cakupan Spark MLlib.

BAB II TINJAUAN PUSTAKA

2.1 Analisis Sentimen

Analisis sentimen (*sentiment analysis*) adalah cabang pemrosesan bahasa alami yang bertujuan mengidentifikasi dan mengklasifikasikan sikap atau opini yang terkandung dalam teks. Pada penelitian ini, tugasnya adalah klasifikasi teks tiga kelas terhadap sebuah narasi tertentu, bukan sekadar polaritas positif/negatif umum, melainkan sikap terhadap kebenaran tuduhan ijazah palsu.

2.2 Big Data dan Karakteristik 3V

Big Data lazim dicirikan dengan tiga dimensi: *Volume* (ukuran data besar), *Velocity* (kecepatan pertumbuhan data), dan *Variety* (keragaman bentuk data). Komentar YouTube memenuhi ketiganya: jumlahnya ribuan hingga jutaan, terus bertambah, serta sangat beragam dan tidak terstruktur (bahasa gaul, singkatan, emoji, campur kode). Untuk menanganinya diperlukan arsitektur penyimpanan dan pemrosesan yang dapat diskalakan secara horizontal.

2.3 MongoDB Atlas: Penyimpanan Terdistribusi

MongoDB adalah basis data NoSQL berorientasi dokumen yang menyimpan data sebagai dokumen JSON/BSON fleksibel, cocok untuk data semi-terstruktur seperti komentar beserta metadatanya. MongoDB Atlas adalah layanan terkelola berbasis awan yang menjalankan MongoDB pada *cluster* dengan replikasi, sehingga menyediakan penyimpanan terpusat yang dapat diakses seluruh tahap pipeline dari mesin mana pun.

2.4 Apache Spark: Pemrosesan Terdistribusi

Apache Spark adalah *engine* komputasi klaster untuk pemrosesan data berskala besar yang bekerja di atas abstraksi *Resilient Distributed Dataset* (RDD) dan *DataFrame*, dengan komputasi in-memory yang cepat. Spark mendistribusikan pekerjaan ke banyak *executor* yang dapat tersebar di beberapa mesin (*worker node*). Pustaka Spark MLlib menyediakan algoritma *machine learning* yang berjalan terdistribusi. Pada proyek ini, Spark digunakan untuk pra-pemrosesan teks terdistribusi, EDA terdistribusi, serta satu varian SVM yang benar-benar berjalan di atas *cluster*.

2.5 SVM dan Pembobotan TF-IDF

Support Vector Machine (SVM) adalah pengklasifikasi yang mencari *hyperplane* pemisah dengan margin maksimum antar-kelas, terkenal efektif untuk klasifikasi teks berdimensi tinggi. Teks direpresentasikan dengan pembobotan TF-IDF (*Term Frequency–Inverse Document Frequency*), yang memberi bobot tinggi pada kata yang sering muncul di sebuah dokumen namun jarang di seluruh korpus. Kombinasi TF-IDF + SVM linier merupakan *baseline* kuat dan ringan secara komputasi untuk klasifikasi teks.

2.6 BERT dan IndoBERTweet

BERT (*Bidirectional Encoder Representations from Transformers*) adalah model bahasa berbasis transformer yang dilatih untuk memahami konteks dua arah. Untuk bahasa Indonesia tersedia beberapa varian terlatih; penelitian ini menggunakan **IndoBERTweet**, yang dilatih spesifik pada data media sosial (Twitter) berbahasa Indonesia sehingga lebih akrab dengan ragam bahasa tidak baku, singkatan, dan gaya percakapan, karakteristik yang dominan pada komentar YouTube. Model ini di-*fine-tune* untuk tugas klasifikasi tiga kelas.

2.7 Pelabelan LLM-assisted dan Label Studio

Pelabelan manual seluruh korpus berskala besar mahal dan lambat. Pendekatan *LLM-assisted labeling* memanfaatkan model bahasa besar untuk memberi label awal secara cepat dan konsisten mengikuti rubrik, kemudian divalidasi manusia pada sampel. **Label Studio** adalah perkakas anotasi sumber terbuka yang dipakai untuk verifikasi manual: task disajikan secara buta (tanpa menampilkan label mesin) agar tidak terjadi bias *anchoring*, dan kesepakatan antar-anotator diukur dengan Cohen’s kappa.


2.8 Metrik Evaluasi

Metrik utama adalah **macro-F1**, yaitu rata-rata F1 tiap kelas dengan bobot setara, sehingga adil terhadap kelas minoritas. Selain itu dilaporkan **akurasi**, **F1 per kelas**, dan **confusion matrix** untuk melihat pola kesalahan antar-kelas. **Cohen’s kappa** digunakan untuk mengukur kesepakatan antara label manusia dan label LLM sebagai indikator mutu korpus.

BAB III METODOLOGI

3.1 Arsitektur Pipeline

Keseluruhan sistem dirancang di sekitar satu sumber data terpusat di MongoDB Atlas (basis data youtube_sentiment). Seluruh data, komentar mentah, hasil label, hingga teks terpra-proses, disimpan sebagai dokumen JSON dalam koleksi terpisah, bukan berkas CSV/Parquet, sehingga seluruh tahap membaca dan menulis ke penyimpanan yang sama. Gambar 3.1 menggambarkan aliran data dari YouTube API hingga perbandingan dua model, termasuk pembagian tahap yang dijalankan terdistribusi di Spark dan yang dijalankan lokal.




Gambar 3.1 Diagram arsitektur pipeline end-to-end, dari YouTube Data API menuju MongoDB Atlas, pra-pemrosesan Spark, hingga perbandingan dua model.

Pembagian *engine* bersifat sengaja: pra-pemrosesan belasan ribu komentar merupakan beban data paralel sehingga didistribusikan ke *cluster* Spark, sedangkan pelatihan IndoBERTweet (PyTorch) dan SVM *baseline* (scikit-learn) dijalankan lokal/GPU karena keduanya bersifat *single-node* secara desain. Sebagai pelengkap sisi Big Data, satu varian SVM tetap diimplementasikan di Spark MLlib agar ada model pembandingan yang benar-benar berjalan terdistribusi.


3.2 Pengumpulan Data

Pengumpulan data dilakukan melalui **YouTube Data API v3** terhadap 17 video terkait isu ijazah Jokowi. Setiap komentar beserta metadatanya (id komentar, id video, teks, waktu) disimpan langsung ke koleksi `raw_comments` di MongoDB Atlas. Proses ingestion mendukung *resume* per video melalui koleksi `ingestion_jobs`, sehingga pengumpulan dapat dilanjutkan tanpa duplikasi bila terputus. Total komentar mentah terkumpul: **14.107 dokumen**.

Gambar 3.2 dan Gambar 3.3 menunjukkan hasil tahap ini di MongoDB Atlas: koleksi `raw_comments` yang memuat komentar mentah beserta metadatanya, dan koleksi `ingestion_jobs` yang mencatat status pengambilan komentar per video.



Gambar 3.2 Koleksi `raw_comments` di MongoDB Atlas (14.107 dokumen komentar mentah beserta metadatanya).



Gambar 3.3 Koleksi `ingestion_jobs`: status pengambilan komentar per video (mendukung resume).

3.3 Pelabelan Data

Pelabelan dilakukan dua lapis. **Lapis pertama, LLM-assisted** (anotator `claude-llm`): 10.000+ komentar diberi label mengikuti rubrik tiga kelas, menghasilkan korpus berlabel berskala besar dalam waktu singkat sebagai dasar pelatihan. **Lapis kedua, verifikasi manual tim** melalui Label Studio yang dihosting daring pada Hugging Face Spaces (kontainer Docker) dengan basis data PostgreSQL persisten di Neon, sehingga anotasi aman tersimpan meski kontainer di-*restart*. Task disajikan **buta** (label mesin tidak ditampilkan) untuk mencegah bias *anchoring*, dan label mesin disimpan terpisah guna menghitung Cohen's kappa.

Untuk pelatihan model dibentuk **dataset seimbang 3.000 komentar (1.000 per kelas)**, di-*sample* dari komentar berlabel dengan *confidence* tinggi. Label dataset ini kemudian **diaudit** ulang terhadap rubrik (versi *v1audited*) untuk memperbaiki inkonsistensi sebelum dijadikan basis angka final.

Gambar 3.4 menampilkan antarmuka Label Studio yang digunakan tim untuk pelabelan dan verifikasi manual.

ID	Completed	text	comment_id
22824	1	Saya yakin (jajah pa Jokowi asli	Ugw5yFvVbR0f8231aLF4AaABag
22825	1	Digelar di gulung ..Jangan mudah terprovokasi dg kelompok kelompok yg	Ugw5yM4d2buD1PBZVBN4AaABag
22826	1	Aku percaya 1000% (jajah pak Jokowi Asli.	UgwDmdOHUqWhq7yCfF4AaABag
22827	1	(jajah pak Jokowi asli di bilang palsu wajo di penjara orang yang	Ugw6m1w3X6EEA3x_Qm94AaABag
22828	1	IAJAZAH JOKOWI ASU ... NO DEBAT ... ASU ASU ASU ... JELAS	UgwW0FPgUUnu3Z4B84AaABag
22829	1	Sehat selalu pak Jokowi (jajah nya asi 🙏🙏🙏	Ugwyyhu7VPz29hAuyd4AaABag
22830	1	q yakin (jajah pk Jokowi asli	UgwCx941JGnkn7nY_J4AaABag
22831	1	Mantap UGM, pernyataan Rektor & jajarannya sudah SANGAT JELAS	Ugx1HyaNZZWgyconMBvd4AaABag
22832	1	Digelar di gulung ..Jangan mudah terprovokasi dg kelompok kelompok yg	UgwvAEXRwLW7dyXV4AaABag
22833	1	Saya percaya jlw (jajah ny asli ...mau putar putar yang otak nya nyengka palsu	UgwvhygDK5NQ1GwW04AaABag
22834	1	(jajah Jokowi Asli	UgySjWytNUPY_3BuLB4AaABag

Gambar 3.4 Antarmuka Label Studio untuk pelabelan/verifikasi manual (project berisi 3.000 task).

3.4 Pra-pemrosesan Terdistribusi (Dua Jalur)

Pra-pemrosesan dijalankan di atas Apache Spark sebagai *User Defined Function* (UDF) pada *executor*, dengan konfigurasi *cluster* antar-mesin: satu Master pada mesin koordinator ditambah *worker* dari mesin anggota lain yang terhubung melalui jaringan *mesh* Tailscale. Konfigurasi ini telah diuji nyata, task terbukti dieksekusi di mesin *remote*, bukan hanya di node lokal, sehingga memenuhi tuntutan pemrosesan benar-benar terdistribusi.


Dibuat **dua jalur pra-pemrosesan terpisah** karena dua paradigma model memiliki kebutuhan berbeda:

- **Jalur SVM** (pembersihan agresif): penyeragaman huruf kecil, pembuangan URL/emoji, normalisasi kata gaul (kamus slang), pembuangan *stopword*, **dengan kata negasi sengaja dipertahankan**, hingga *stemming* Sastrawi. Alasannya, SVM adalah model *bag-of-words* yang tidak memahami konteks, sehingga teks harus diseragamkan agar kata seakar dianggap sama. Hasil ditulis ke koleksi *processed_svm*.
- **Jalur IndoBERTweet** (pembersihan minimal): hanya *lowercase* dan pembuangan URL/mention/emoji; tanda baca, imbuhan, dan negasi dipertahankan utuh. Alasannya, transformer memahami konteks melalui


tokenizer *subword*, sehingga morfologi justru membantu dan *stemming* malah merusak. Hasil ditulis ke koleksi `processed_bert`.

Keputusan **mempertahankan negasi** (tidak, bukan, belum dikeluarkan dari daftar *stopword*) bersifat krusial: bila negasi ikut dibuang, frasa “*tidak palsu*” menjadi setara “*palsu*”, kesalahan fatal untuk analisis sentimen.

Hasil kedua jalur pra-pemrosesan disimpan pada koleksi terpisah di MongoDB Atlas, seperti ditunjukkan pada Gambar 3.5 dan Gambar 3.6. Perhatikan perbedaan kolom hasil: `svm` (teks dipadatkan dan di-stem) versus `bert` (teks dipertahankan hampir utuh).



Gambar 3.5 Koleksi `processed_svm`: teks hasil pra-pemrosesan jalur SVM (kolom `svm`, dipadatkan).



Gambar 3.6 Koleksi processed_bert: teks hasil pra-pemrosesan jalur IndoBERTweet (kolom bert, morfologi utuh).

3.5 Desain Dataset dan Pembagian Data

Pembagian data dilakukan **deterministik**, diurutkan berdasarkan comment_id, seed 42, rasio **70/20/10** (train/validation/test), dan dihitung **sebelum** pra-pemrosesan. Dengan demikian kedua model dievaluasi pada *test set* yang **identik**, sehingga perbandingan benar-benar *apple-to-apple*. Pada dataset seimbang 3.000, komposisi uji adalah 300 komentar (≈ 100 per kelas).

3.6 Pemodelan

Dua model utama dilatih di atas data dan *split* yang sama, ditambah satu varian Spark dari SVM sebagai demonstrasi Big Data:

1. **SVM + TF-IDF (scikit-learn)**, *baseline* utama. TF-IDF dengan *sublinear TF* dan normalisasi L2, pengklasifikasi LinearSVC, penyetelan *hyperparameter* via GridSearchCV ($\text{ngram} \times \text{min_df} \times C$) di *validation set*.
2. **IndoBERTweet** (indolem/indobertweet-base-uncased), model transformer domain media sosial, di-*fine-tune* 4 epoch, *learning rate* $2e-5$, *batch* 16, *max_len* 128, pemilihan *checkpoint* terbaik berdasarkan macro-F1 validasi (PyTorch, Colab GPU).
3. **SVM Spark MLlib**, replikasi model SVM pada *engine* terdistribusi (CountVectorizer $\rightarrow$ IDF $\rightarrow$ L2 $\rightarrow$ OneVsRest(LinearSVC)) sebagai jalur pembandingan sisi Big Data.

3.7 Metrik Evaluasi

Metrik utama adalah **macro-F1** pada *test set*, didukung akurasi, F1 per kelas, dan *confusion matrix*. Pada dataset seimbang, akurasi ikut bermakna karena tidak bias ke kelas mayoritas.


BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Pengumpulan dan Karakteristik Data

Pengumpulan menghasilkan **14.107 komentar** dari 17 video. Karena distribusi kelas pada korpus terkumpul cukup timpang, kelas Netral paling langka, untuk pemodelan diambil subset **seimbang 3.000 komentar** (1.000 per kelas) agar evaluasi antar-kelas adil dan macro-F1 bermakna.

4.2 Analisis Data Eksploratif (EDA Terdistribusi)

EDA dihitung secara terdistribusi di Spark (agregasi groupBy/explode/join). Gambar 4.1 merangkum distribusi kelas dan rata-rata panjang teks per tahap. Efek dua jalur pra-pemrosesan terlihat jelas: jalur SVM memangkas rata-rata panjang dari **15,3 kata** menjadi **11,6 kata** (akibat pembuangan *stopword* dan *stemming*), sedangkan jalur BERT mempertahankannya di **15,2 kata**. Ukuran kosakata jalur SVM adalah 14.844 kata unik, dengan proporsi teks kosong 0,52% dan duplikat 1,45% (dilaporkan apa adanya).



Gambar 4.1 Distribusi kelas korpus dan rata-rata jumlah kata per tahap pra-pemrosesan (mentah vs jalur SVM vs jalur BERT).

Kata paling sering muncul (setelah pembersihan) adalah *tidak*, *jokowi*, *roy*, *orang*, *ijazah*, *palsu*, *asli*, dan *benar*, mengonfirmasi bahwa sinyal isu ini sangat leksikal dan berpusat pada perdebatan asli/palsu.

4.3 Hasil Pelabelan dan Validasi Manusia

Pelabelan LLM menghasilkan korpus berlabel berskala besar. Verifikasi manual melalui Label Studio menunjukkan kecenderungan rubrik manusia yang konservatif (banyak komentar yang hanya menyerang pihak tertentu tanpa


menyatakan sikap atas tuduhan dinilai Netral). Untuk pelatihan model, digunakan **dataset seimbang 3.000** yang labelnya telah diaudit (*v1audited*) demi konsistensi terhadap rubrik.

4.4 Hasil Perbandingan Model (Dataset Final Seimbang 3.000)

Tabel 4.1 menyajikan hasil kedua model pada *test set* identik (300 komentar). **IndoBERTweet memberikan performa terbaik**, sedikit di atas SVM + TF-IDF.

Tabel 4.1 Perbandingan metrik kedua model pada *test set* dataset seimbang 3.000 (*v1audited*).

Model	Akurasi	Macro-F1	F1 Negatif	F1 Netral	F1 Positif
SVM + TF-IDF (sklearn)	0,8567	0,8556	0,8148	0,8867	0,8654
IndoBER Tweet	0,8733	0,8721	0,8254	0,8976	0,8932




Gambar 4.2 Perbandingan akurasi dan macro-F1 kedua model pada dataset seimbang 3.000.

IndoBERTweet unggul karena model dasarnya dilatih pada data media sosial sehingga lebih akrab dengan ragam bahasa komentar YouTube yang tidak baku. Menariknya, **selisih kedua model tergolong tipis** (akurasi 0,8567 → 0,8733; hanya ≈1,7 poin). Artinya, pada kasus dengan sinyal yang sangat leksikal (kata *palsu/asli/bohong/fitnah*) dan data seimbang berkualitas, *baseline* klasik SVM tetap


sangat kompetitif dengan biaya komputasi yang jauh lebih ringan daripada transformer.

4.5 Analisis per Kelas dan Confusion Matrix

Gambar 4.3–4.4 menampilkan *confusion matrix* kedua model. Pada dataset seimbang, kelas **Negatif** memiliki F1 terendah pada kedua model (SVM 0,8148; IndoBERTweet 0,8254): kesalahan tersering adalah komentar Negatif yang diprediksi Positif (13 kasus pada SVM, 11 pada IndoBERTweet). Hal ini masuk akal karena menolak tuduhan (Negatif) dan mendukung tuduhan (Positif) sama-sama berkuat pada kosakata yang sama (*ijazah, palsu, asli*), sehingga sulit dibedakan tanpa benar-benar memahami sikap penulis. IndoBERTweet unggul pada seluruh kelas, dengan keunggulan terbesar pada kelas Positif (0,8932 vs 0,8654), berkat pemahaman konteks dari model dasarnya.



Gambar 4.3 Confusion matrix SVM + TF-IDF (test set, 300 komentar).



Gambar 4.4 Confusion matrix IndoBERTweet (test set, 300 komentar), model terbaik.

4.6 Eksperimen Kualitas Label

Sebuah eksperimen menguji apakah membersihkan label secara otomatis (relabel konsensus LLM tiga-lapis) dapat menaikkan performa. Hasilnya jujur dilaporkan: **relabel LLM tidak memberi peningkatan macro-F1 yang terukur**. Sebaliknya, audit label terhadap rubrik (*v1audited*) sedikit menaikkan performa (misalnya SVM 0,84 $\rightarrow$ 0,8567). Kesimpulannya, tanpa *gold-standard* manusia, plafon performa lebih ditentukan oleh **ambiguitas tugas** (khususnya Negatif $\leftrightarrow$ Positif) daripada derau label yang dapat dibersihkan otomatis.

4.7 Jalur Big Data: SVM Spark vs scikit-learn

Sebagai bukti pemrosesan terdistribusi, varian SVM diimplementasikan di Spark MLlib dan dijalankan di atas *cluster*. Macro-F1-nya sedikit di bawah scikit-learn. Selisih ini **bukan bug atau kesalahan penyetelan**, melainkan perbedaan struktural: Spark MLlib CountVectorizer+IDF tidak memiliki *sublinear TF*, multiclass ditangani lewat *OneVsRest*, dan regularisasi diparametri regParam alih-alih C. Pola kesalahan antar-kelas tetap serupa. Karena itu, angka final memakai scikit-learn, sementara Spark dilaporkan sebagai jalur Big Data yang setara secara metodologi.

4.8 Kendala dan Solusi

Tabel 4.2 merangkum kendala teknis utama beserta solusinya.

Tabel 4.2 Kendala teknis utama dan solusinya.

Kendala	Solusi
Worker Spark <i>remote</i> mati saat sesi SSH/Tailscale ditutup	Worker dijalankan di <i>foreground</i> pada terminal yang dibiarkan terbuka
Executor <i>remote</i> gagal karena beda versi Spark/dependensi UDF	Versi PySpark disamakan; Arrow dimatikan di mode <i>cluster</i> agar job murni-JVM
Token akses Label Studio (PAT) ditolak walau belum kedaluwarsa	HF Space me-rotasi <i>signing key</i> saat <i>restart</i> → regenerasi PAT baru
Cluster tanpa HDFS, data hanya di koordinator	Data direplikasi ke tiap <i>worker</i> via skrip sinkronisasi sebelum submit job
Java 21 tidak didukung Spark 3.5	Menggunakan Spark 4.x yang kompatibel dengan Java 21

BAB V PENUTUP

5.1 Kesimpulan

Proyek ini berhasil membangun pipeline analisis sentimen *end-to-end* di atas infrastruktur Big Data yang nyata, dengan **MongoDB Atlas** sebagai penyimpanan terpusat dan **Apache Spark** sebagai mesin pemrosesan terdistribusi yang terbukti mengeksekusi task pada mesin lintas-jaringan melalui Tailscale. Strategi dua jalur pra-pemrosesan, yakni pembersihan agresif untuk SVM dan pembersihan minimal untuk transformer, beserta keputusan mempertahankan kata negasi, terbukti tepat untuk kebutuhan masing-masing paradigma model.

Pada dataset seimbang 3.000 komentar, IndoBERTweet menjadi model terbaik dengan akurasi 0,8733 dan macro-F1 0,8721, sedikit mengungguli SVM + TF-IDF (0,8567). Namun selisih keduanya tergolong tipis (sekitar 1,7 poin), yang menunjukkan bahwa model klasik SVM masih sangat kompetitif untuk kasus berbasis sinyal leksikal seperti ini dengan biaya komputasi yang jauh lebih ringan. Dari sisi pola kesalahan, kelas Negatif memiliki F1 terendah pada kedua model dan paling sering tertukar dengan kelas Positif karena keduanya berbagi kosakata isu yang sama, sehingga plafon performa lebih ditentukan oleh ambiguitas tugas daripada derau label.

5.2 Saran

Terdapat beberapa hal yang dapat dikembangkan pada penelitian selanjutnya. Verifikasi manual berskala lebih besar beserta perhitungan Cohen's kappa perlu dituntaskan untuk memperkuat validitas korpus sebagai *gold-standard*. Selain itu, dapat diuji fitur atau strategi yang lebih baik untuk membedakan kutub Negatif dan Positif yang berbagi kosakata isu, misalnya fitur berbasis negasi atau relasi maupun model yang lebih peka konteks. Pendekatan *ensemble* antara SVM dan transformer juga layak dieksplorasi untuk memadukan efisiensi model klasik dengan pemahaman konteks transformer. Terakhir, sumber data perlu diperluas dengan lebih banyak video atau isu agar generalisasi model pada distribusi dunia nyata yang timpang dapat diuji.

DAFTAR PUSTAKA

- Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297.
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186.
- Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP. *Proceedings of COLING 2020*, 757–770.
- Koto, F., Lau, J. H., & Baldwin, T. (2021). IndoBERTweet: A Pretrained Language Model for Indonesian Twitter with Effective Domain-Specific Vocabulary Initialization. *Proceedings of EMNLP 2021*, 10660–10668.
- Salton, G., & Buckley, C. (1988). Term-weighting Approaches in Automatic Text Retrieval. *Information Processing & Management*, 24(5), 513–523.
- Wilie, B., dkk. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. *Proceedings of AACL-IJCNLP 2020*, 843–857.
- Zaharia, M., dkk. (2016). Apache Spark: A Unified Engine for Big Data Processing. *Communications of the ACM*, 59(11), 56–65.
- MongoDB, Inc. (2024). *MongoDB Atlas Documentation*. Diakses dari <https://www.mongodb.com/docs/atlas/>
- Google Developers. (2024). *YouTube Data API v3 Documentation*. Diakses dari <https://developers.google.com/youtube/v3>

LAMPIRAN, PEMBAGIAN TUGAS (PIC)

Tabel L.1 Pembagian tugas (Person In Charge) pengerjaan proyek.

No	Tahap Pekerjaan	Uraian Tugas	PIC
1	Pengumpulan Data	Pengambilan komentar via YouTube Data API v3 dan penyimpanan ke MongoDB Atlas	Ida Bagus Gede Dhananjaya (2305551120)
2	Pelabelan Data	Pelabelan LLM-assisted, hosting Label Studio, dan verifikasi manual tim	Ravi Arnan Irianto (2305551076)
3	Pra-pemrosesan	Pipeline Apache Spark antar-mesin, dua jalur (SVM & IndoBERTweet)	Ravi Arnan Irianto (2305551076)
4	Pemodelan & Evaluasi	Pelatihan SVM + TF-IDF dan IndoBERTweet serta perbandingan metrik	Ravi Arnan Irianto (2305551076)
5	Visualisasi	Pembuatan dashboard visualisasi (Streamlit) dan Tableau	Ida Bagus Gede Dhananjaya (2305551120)
6	Penyusunan	Kompilasi dan	Ravi Arnan

No	Tahap Pekerjaan	Uraian Tugas	PIC
	Laporan	penulisan laporan akhir	Irianto & Ida Bagus Gede Dhananjaya